UT CHETUMAL

Desarrollo y Gestión de Software

Extracción de conocimiento en bases de datos

Dr. Martín Antonio Santos Romero

T.S.U. Miguel Ángel Peña Pech

9no cuatrimestre

Actividad 2

El proceso de ciencia de datos

Índice

Introducción

Con base al libro Cielen, D., Meysman, A., & Ali, M. (2016).

Figura 1. Proceso de la Ciencia de Datos

Tabla 1. Proceso de la Ciencia de Datos (Cielen et al., 2016)

Tabla 2. Técnicas por Etapa (Cielen et al., 2016)

Con base al libro electrónico en la plataforma eLibro.net "Maldonado, S. (2022). Analytics y Big Data.

Figura 2. Analytics y Big Data

Tabla 3. Proceso de Ciencia de Datos (Maldonado, 2022)

Tabla 4. Técnicas por Etapa (Maldonado, 2022)

Conclusión

Bibliografía

Introducción

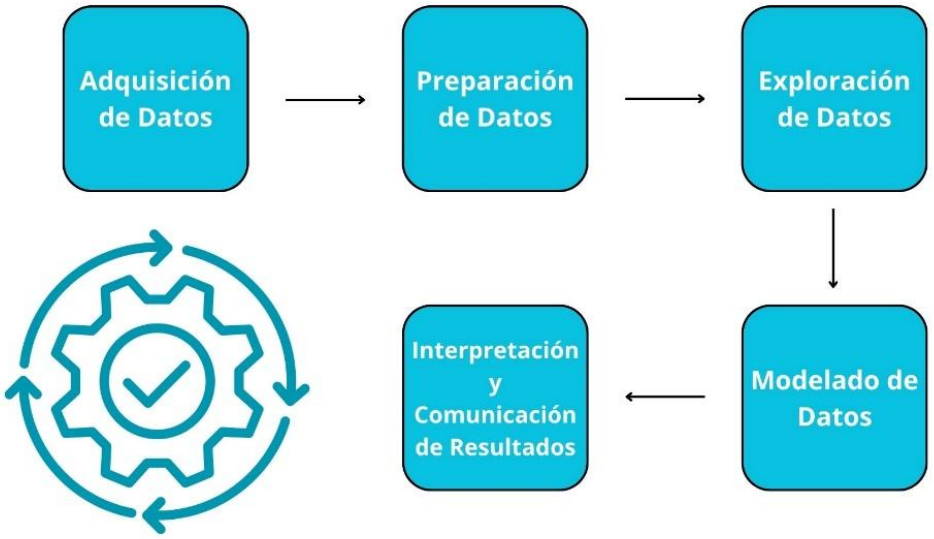
La ciencia de datos se ha convertido en una herramienta esencial para las organizaciones que buscan tomar decisiones informadas basadas en grandes volúmenes de información. Esta disciplina combina conocimientos de estadística, programación y entendimiento del negocio para transformar datos crudos en conocimiento útil. En el presente trabajo se abordan dos enfoques metodológicos sobre el proceso de extracción de conocimiento a partir de datos, según los autores Cielen et al. (2016) y Maldonado (2022). Ambos modelos permiten comprender las etapas clave del ciclo de vida de los datos, desde su adquisición hasta la interpretación de los resultados, haciendo uso de diversas técnicas de análisis y visualización.

1. Con base al libro Cielen, D., Meysman, A., & Ali, M. (2016).

Introducing Data Science. Manning Publications:

Este libro ofrece una visión clara y estructurada del proceso de la ciencia de datos, una disciplina que combina conocimientos en estadística, programación y comprensión del negocio para extraer valor a partir de grandes volúmenes de información.

Figura 1. Proceso de la Ciencia de Datos.



Fuente: Ángel Peña (2025).

Tabla 1. Proceso de la Ciencia de Datos.

1	Adquisición de Datos
La primera etapa consiste en obtener los datos necesarios desde distintas fuentes internas o externas. Estos pueden provenir de bases de datos transaccionales, archivos planos (CSV, Excel), APIs de servicios externos, sensores o incluso redes sociales.	
2	Preparación de Datos
Una vez recolectada la información, es necesario prepararla para su análisis. Esta etapa consiste en detectar y corregir errores, eliminar duplicados, manejar los valores faltantes y asegurar la coherencia de los datos. Es fundamental para garantizar la calidad del análisis posterior.	
3	Exploración de Datos
Una vez limpios los datos, se procede a analizarlos para descubrir patrones, tendencias o comportamientos relevantes. El análisis exploratorio tiene como objetivo generar una comprensión profunda del conjunto de datos y orientar las siguientes etapas del proceso.	
4	Modelado de Datos
En esta etapa se aplican algoritmos de aprendizaje automático o estadística para crear modelos que permitan hacer predicciones o clasificaciones. Dependiendo del objetivo, se pueden usar técnicas como regresión, clasificación o agrupamiento (clustering).	

5	Interpretación y Comunicación de Resultados
El último paso consiste en analizar los resultados del modelo, interpretarlos en el contexto del problema y comunicarlos de forma clara y comprensible.	

Fuente: Ángel Peña (2025).

Tabla 2. Técnicas de capas.

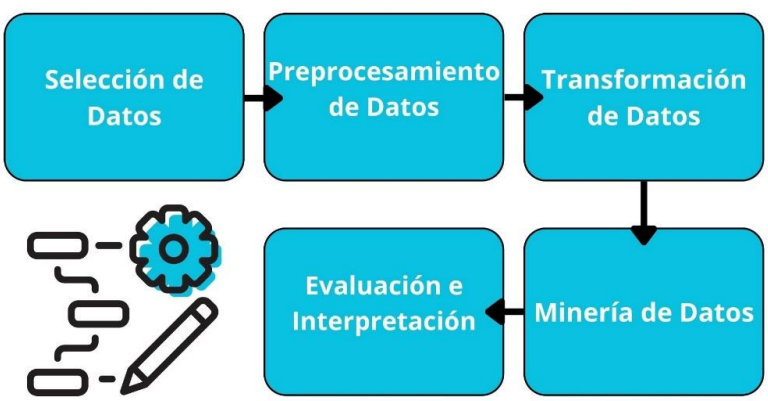
Adquisición de Datos (Data Acquisition)	
¿Qué se hace?	Recolectar datos desde diversas fuentes como bases de datos, archivos, APIs, sensores, redes sociales, etc.
Técnicas utilizadas	
Web Scraping	Para obtener datos desde páginas web. **Ejemplo:** Usar BeautifulSoup para extraer información de noticias.
APIs	Para acceder a plataformas como Twitter, Facebook, Google Maps. **Ejemplo:** Descargar tuits relacionados con una palabra clave.
Conexiones a bases de datos SQL/NoSQL	Para extraer datos estructurados. **Ejemplo:** Obtener registros de ventas desde una base de datos MySQL.
Preparación de Datos (Data Preparation o Data Cleaning)	
¿Qué se hace?	Limpiar, transformar y organizar los datos para que sean utilizables.
Técnicas utilizadas	
Imputación de valores faltantes	Rellenar datos nulos con la media, mediana o mediante modelos. **Ejemplo:** Rellenar edades faltantes con la media del conjunto.
Eliminación de duplicados y outliers	Para evitar sesgos. **Ejemplo:** Eliminar registros de usuarios duplicados.
Normalización o estandarización	Para escalar los datos. **Ejemplo:** Convertir ingresos a una misma escala para modelos predictivos.
Exploración de Datos (Data Exploration)	
¿Qué se hace?	Analizar los datos para entender patrones, relaciones y distribuciones.
Técnicas utilizadas	
Visualización de datos	Histogramas, gráficos de dispersión, boxplots. **Ejemplo:** Un histograma que muestre la edad de los clientes.
Estadística descriptiva	Medias, medianas, desviaciones estándar. **Ejemplo:** Calcular el promedio de ventas por región.
Análisis de correlación	Para detectar relaciones entre variables. **Ejemplo:** Ver si el precio afecta directamente las ventas.
Modelado de Datos (Data Modeling)	
¿Qué se hace?	Construir modelos estadísticos o de aprendizaje automático para predecir o clasificar.
Técnicas utilizadas	
Regresión	Para predecir valores continuos. **Ejemplo:** Predecir el ingreso mensual de un cliente.
Clasificación	Para categorizar resultados.. **Ejemplo:** Predecir si un cliente comprará (sí/no).

Clustering (agrupamiento)	Para segmentar grupos similares. **Ejemplo:** Agrupar clientes según comportamiento de compra.
Interpretación y Comunicación de Resultados (Data Interpretation and Communication)	
¿Qué se hace?	Traducir los resultados del análisis y modelos a información útil para la toma de decisiones.
Técnicas utilizadas	
Dashboards	Presentar métricas clave de forma visual. **Ejemplo:** Power BI o Tableau mostrando ventas por zona.
Storytelling con datos	Combinar narrativa y visualizaciones para explicar hallazgos. **Ejemplo:** Contar cómo una campaña de marketing impactó en las ventas.
Reportes ejecutivos	Informes escritos con conclusiones claras para no técnicos.

Fuente: Ángel Peña (2025).

2. Con base al libro electrónico en la plataforma eLibro.net **“Maldonado, S. (2022). Analytics y Big Data.**
Ciencia de los Datos aplicada al mundo de los negocios.

Figura 2. Analytics y Big Data.



Fuente: Ángel Peña (2025).

Tabla 3. Proceso de la Ciencia de Datos.

1	Selección de Datos
En esta primera etapa se identifican las fuentes de datos relevantes para el análisis. Se busca elegir aquellos conjuntos de datos que contienen la información útil y significativa para los objetivos del proyecto. Es fundamental conocer bien el dominio del problema para saber qué datos pueden tener valor.	
2	Preprocesamiento de Datos
Una vez seleccionados los datos, se realiza la limpieza y preparación de estos. Esta etapa se centra en corregir errores, eliminar registros duplicados, tratar valores faltantes, y asegurar que la calidad de los datos sea adecuada.	
3	Transformación de Datos
Aquí se modifican y convierten los datos en un formato más adecuado para el análisis. Esto incluye la normalización de valores, la agregación de datos, la creación de nuevas variables derivadas y la codificación de categorías. El objetivo es facilitar la extracción de patrones y relaciones significativas.	
4	Minería de Datos
Es la etapa central del proceso, en la que se aplican técnicas estadísticas, algoritmos de aprendizaje automático o inteligencia artificial para encontrar patrones, correlaciones o modelos predictivos.	
5	Evaluación e Interpretación
Finalmente, los resultados obtenidos se analizan para determinar si son válidos, útiles y comprensibles para los usuarios finales.	

Fuente: Ángel Peña (2025).

Tabla 4. Características Analytic y Big Data.

Selección de Datos	
¿Qué se hace?	Se identifican, recopilan y seleccionan los datos relevantes desde múltiples fuentes (bases de datos, archivos planos, APIs, sensores, etc.).
Técnicas utilizadas	
• SQL para extraer datos de bases de datos. • Web scraping para recolectar datos desde sitios web. • Conectores API para acceder a servicios como Google Analytics.	
Ejemplo	Recopilar información de ventas, clientes y productos de un sistema ERP.
Preprocesamiento de Datos	
¿Qué se hace?	Se limpian y corrigen los datos: eliminación de duplicados, manejo de valores nulos, detección de errores.
Técnicas utilizadas	
• Limpieza de datos (data cleaning). • Imputación de valores faltantes. • Detección de outliers.	
Ejemplo	Reemplazar valores nulos en la columna de edad con la media.
Transformación de Datos	
¿Qué se hace?	Se preparan los datos para análisis: normalización, reducción de dimensiones, creación de nuevas variables.
Técnicas utilizadas	
• Normalización y estandarización. • PCA (Análisis de Componentes Principales) para reducir dimensiones. • Codificación One-Hot o Label Encoding.	
Ejemplo	Convertir la fecha de nacimiento en edad o codificar variables categóricas.
Minería de Datos	
¿Qué se hace?	Se aplican algoritmos para descubrir patrones, relaciones y modelos.
Técnicas utilizadas	
• Árboles de decisión, redes neuronales, K-means, regresión logística • Reglas de asociación (Apriori). • Clustering o agrupamiento.	
Ejemplo	Usar un modelo de clasificación para predecir si un cliente comprará un producto.
Evaluación e Interpretación	
¿Qué se hace?	Se validan los resultados, se interpretan los patrones y se presentan hallazgos útiles para la toma de decisiones.
Técnicas utilizadas	
• Métricas de evaluación (precisión, recall, F1). • Visualización de datos (gráficos, dashboards). • Interpretación con herramientas como SHAP o LIME.	
Ejemplo	Mostrar en una gráfica que los clientes de entre 25 y 35 años son los que más compran un servicio.

Fuente: Ángel Peña (2025).

Conclusión

A través del análisis comparativo de los enfoques de Cielen et al. (2016) y Maldonado (2022), se puede observar que, aunque usan diferentes terminologías, ambos coinciden en la importancia de una estructura ordenada para extraer valor de los datos. Desde la adquisición y limpieza de la información, pasando por su modelado, hasta la interpretación y presentación de resultados, cada paso es clave para obtener conocimiento accionable.

Bibliografía

Cielen, D., Meysman, A., & Ali, M. (2016). Introducing Data Science: Big Data, Machine Learning, and more, using Python tools. Manning Publications. Disponible en: https://www.manning.com/books/introducing-data-science

Maldonado, S. (2022). Analytics y Big Data: Ciencia de los Datos aplicada al mundo de los negocios. RIL Editores. Disponible en eLibro.net: https://elibro.net/es/ereader/utchetumal/225562

IBM Data Science Community. (s.f.). The Data Science Process. Disponible en: https://community.ibm.com

Towards Data Science. (s.f.). Data Science Lifecycle. Medium. Disponible en: https://towardsdatascience.com/