UT CHETUMAL

Desarrollo y Gestión de Software

Extracción de conocimiento en bases de datos

Dr. Martín Antonio Santos Romero

T.S.U. Miguel Ángel Peña Pech

9no cuatrimestre

Actividad Formativa 3

Algoritmos de aprendizaje supervisado

Índice

Introducción 3

Tareas a realizar por el alumno 4

Conclusión 11

Bibliografía 12

Introducción

El aprendizaje supervisado es una de las ramas más utilizadas de la inteligencia artificial, permitiendo que las máquinas aprendan a partir de datos etiquetados para realizar predicciones precisas. En esta investigación se abordan los algoritmos más representativos de esta técnica, como el árbol de decisión, máquinas de soporte vectorial (SVM), Naive Bayes, KNN, regresiones, redes neuronales y CNN, explicando sus principios, funcionamiento y casos de aplicación. Además, se realizó un análisis comparativo y visual mediante una infografía digital, y se integró una investigación académica basada en artículos científicos actuales para ejemplificar el uso real de cada algoritmo en distintos sectores.

Tareas a realizar por el alumno

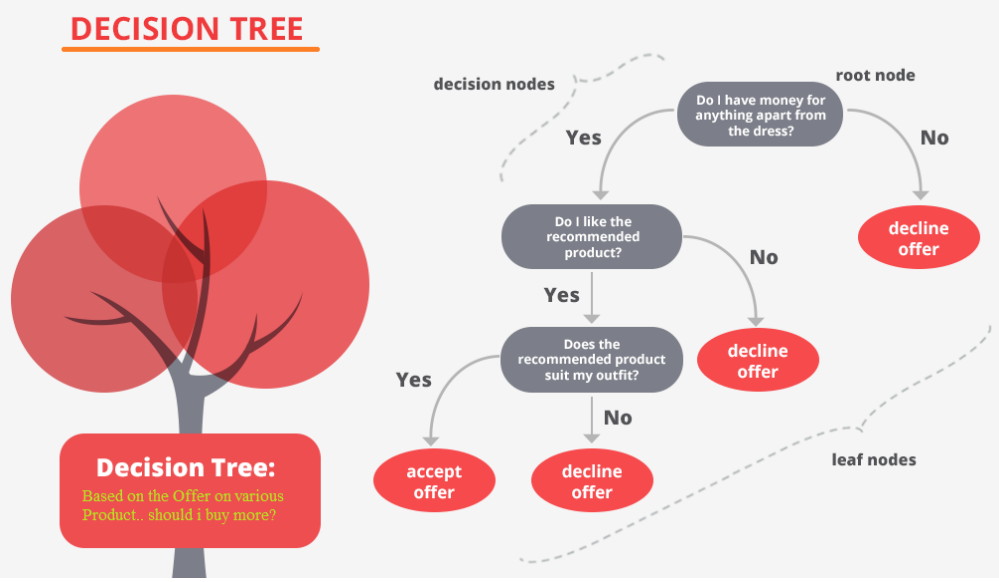
Realiza una investigación completa en fuentes confiables sobre los principales algoritmos de aprendizaje supervisado, considerando definición, explicación breve de su funcionamiento, y principales casos de aplicación.

-Decision Tree
-Support Vector Machine (SVM)
-Naive Bayes
-K-Nearest Neighbors (KNN)
-Regresión lineal
-Regresión logística
-Support Vector machine regression (SVR)
-Redes neuronales
-Redes neuronales convolucionales (CNN)

1. Decision Tree (Árbol de Decisión).

Decision Tree	
Definición	Un árbol de decisión es un modelo de aprendizaje supervisado no paramétrico que construye una estructura jerárquica de reglas simples (nodos) para dividir datos en subgrupos homogéneos. Su objetivo es mapear características (inputs) a decisiones (outputs) mediante bifurcaciones sucesivas basadas en condiciones de tipo "if-then".
Características	• **Nodos**: ○ *Raíz*: Primera condición que divide los datos. ○ **I***nternos*: Preguntas sobre características (ej. *¿Edad > 30?*). ○ *Hojas*: Resultados finales (clases o valores numéricos). • **Métricas de división**: ○ *Gini impurity*: Mide la frecuencia de clasificación incorrecta. ○ *Entropía*: Cuantifica el desorden en los subgrupos.

Figura 1.



Fuente: Bootcamp AI (2020).

2. Support Vector Machine (SVM).

Support Vector Machine	
Definición	SVM es un algoritmo de clasificación binaria (extensible a multiclase) que encuentra el hiperplano óptimo en un espacio de alta dimensión para separar clases maximizando el margen (distancia al punto más cercano de cada clase). Usa kernels para transformar datos no separables linealmente.
Características	• **Vectores de soporte:** Puntos de datos más cercanos al hiperplano, que definen su posición. • **Margen:** Zona libre de datos entre clases. • **Kernels:** Funciones que proyectan datos a espacios dimensionales superiores: ○ **Lineal:** Para separación lineal. ○ **RBF (Radial Basis Function):** Para patrones complejos no lineales.
Fórmula	$w \cdot x - b = 0$

3. Naive Bayes.

Naive Bayes	
Definición	Clasificador probabilístico basado en el teorema de Bayes con una suposición simplificadora ("naive"): las características son independientes entre sí dada la clase.
Características	Calcula la probabilidad posterior de una clase Ck dado un vector de características x.
Fórmula	$P(C_k\|x) = \frac{P(x\|C_k) \cdot P(C_k)}{P(x)}$
Variantes y limitaciones	**Variantes:** *GaussianNB:* Asume distribución normal en características continuas. *MultinomialNB:* Para datos discretos (ej. conteos de palabras). *BernoulliNB:* Características binarias (ej. presencia/ausencia). **Limitación:** La independencia de características rara vez se cumple en la realidad, pero aún funciona bien en muchos casos.

4. K-Nearest Neighbors (KNN).

K-Nearest Neighbors	
Definición	Algoritmo de aprendizaje basado en instancias (no genera un modelo explícito) que clasifica o predice basándose en la mayoría o promedio de los k ejemplos más cercanos en el espacio de características.
Características	• **Distancia:** Métricas comunes: ○ ***Euclidiana*:** ∑(xi−yi)2∑(*xi*−*yi*)2. ○ ***Manhattan*:** ∑|xi−yi|∑|*xi*−*yi*|. • **Parámetro k*k*:** ○ **k*k* bajo** → Sensible a ruido. ○ **k*k* alto** → Suaviza fronteras pero puede perder detalle.

Ejemplo	Si k=3 y los 3 vecinos más cercanos a un punto son [A, A, B], **se clasifica como clase *A*.**

5. Regresión Lineal

Regresión Lineal	
Definición	Modelo que establece una relación lineal entre variables independientes (XX) y una dependiente (YY), minimizando la suma de errores cuadrados.
Características	*Supuestos Críticos:* 1. **Linealidad:** La relación entre X*X* e Y*Y* es lineal. 2. **Homocedasticidad:** Varianza constante del error. 3. **Independencia:** Los residuos no están correlacionados. *Extensión:* • **Regresión lineal múltiple:** Usa varias variables X1,X2,...,Xn*X*1,*X*2,...,*Xn*.
Fórmula	$$Y = \beta_0 + \beta_1 X + \epsilon$$ • β_0: Intercepto. • β_1: Pendiente. • ϵ: Error aleatorio.

6. Regresión Logística.

Regresión Logística	
Definición	Aunque se llama "regresión", es un algoritmo de clasificación binaria que modela la probabilidad de pertenecer a una clase usando la función sigmoide.
Características	***Interpretación***: • *Salida entre 0 y 1 (probabilidad).* • *Umbral común: 0.5 (si P≥0.5P≥0.5, clase 1).* ***Casos Especiales***: • ***Multiclase**: Usa estrategias one-vs-rest o softmax.*
Fórmula	$$P(Y = 1\|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

7. Support Vector Regression (SVR).

Support Vector Regression	
Definición	Variante de SVM para regresión, que busca ajustar los datos dentro de un margen de error ϵ (tubo épsilon), ignorando errores menores a ϵ.
Características	C: Controla el trade-off entre margen y errores. ξi,ξi∗: Variables de holgura para puntos fuera del tubo. **Kernel Trick:** Permite modelar relaciones no lineales sin transformar manualmente los datos.

Fórmula	$\text{Minimizar } \frac{1}{2}\|w\|^2 + C\sum(\xi_i + \xi_i^*)$

8. Redes Neuronales (ANN).

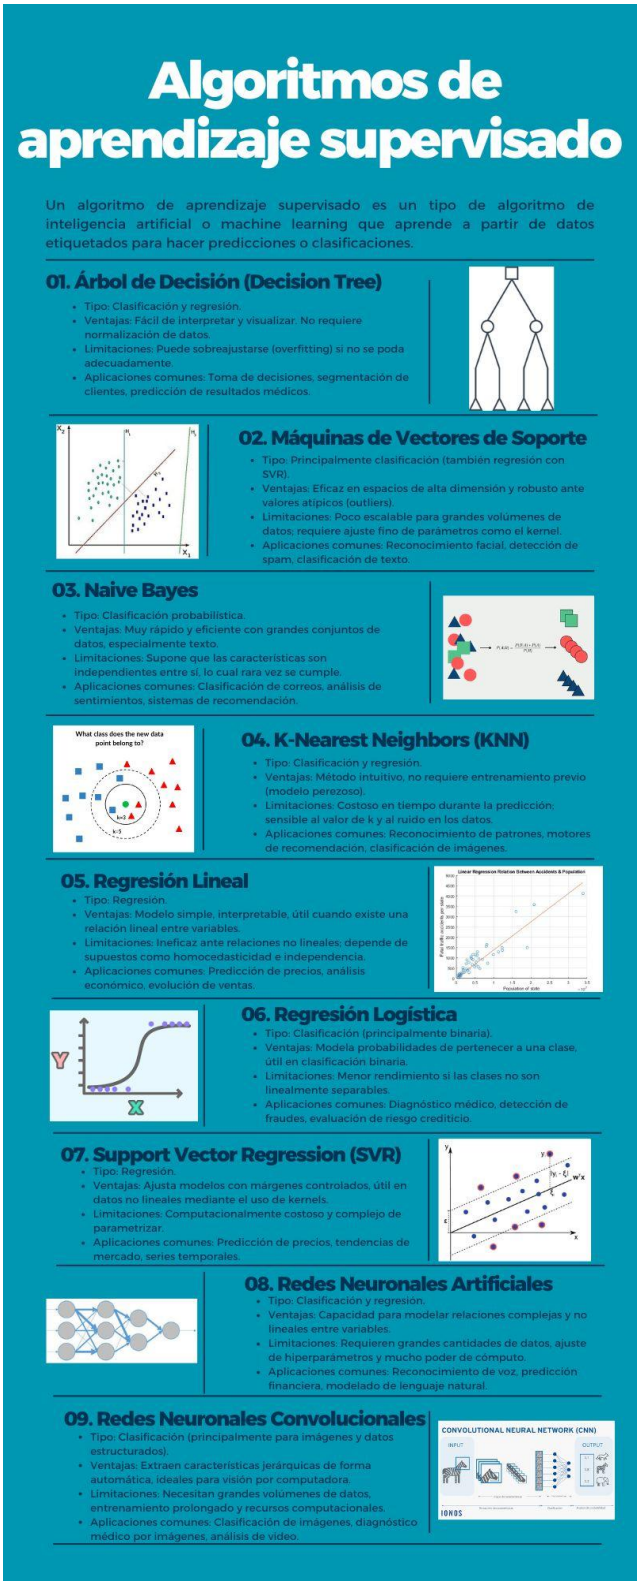
Redes Neuronales	
Definición	Sistemas inspirados en neuronas biológicas, compuestos por capas de nodos (neuronas artificiales) que transforman inputs mediante pesos ajustables y funciones de activación.
Características	**Capa de entrada:** Recibe los datos. **Capas ocultas:** Realizan transformaciones no lineales. **Capa de salida:** Genera la predicción.
Función de Activación	**ReLU:** f(x)=max⁡(0,x)f(x)=max(0,x) (para no linealidad). **Sigmoide:** Para probabilidades.

9. Redes Neuronales Convolucionales (CNN).

Redes Neuronales Convolucionales	
Definición	Redes especializadas en datos con estructura grid (imágenes, secuencias), que usan convoluciones para extraer características jerárquicas (bordes → formas → objetos).
Características	**Capas principales:** 1. **Convolucional:** Aplica filtros (kernels) para detectar patrones locales. 2. **Pooling:** Reduce dimensionalidad conservando características dominantes. 3. **Fully Connected:** Conecta todas las neuronas para clasificación.
Ejemplo	**Ejemplo en Visión por Computadora**: • Una CNN para reconocer gatos podría aprender: ○ Capa 1: Bordes. ○ Capa 2: Orejas/ojos. ○ Capa 3: Rostro completo.

Con base a la información que presentas, realiza un análisis comparativo sobre los algoritmos de aprendizaje supervisado; y preséntalo en un organizador gráfico, como puede ser una infografía.

Figura 2.



Fuente: Angel Peña (2025).

Investiga y presenta un ejemplo actual de aplicación de los algoritmos de aprendizaje supervisado anteriores.

Información del URL:
https://sciendo.com/article/10.2478/amns-2024-1463

Aplicación del árbol de decisiones y el aprendizaje automático en la toma de decisiones de mantenimiento de vehículos de nueva energía

Varios incidentes de combustión de vehículos eléctricos en diversas regiones de China han puesto de relieve en el discurso público las preocupaciones de seguridad asociadas con los vehículos de nuevas energías. Para abordar estas preocupaciones, este artículo explora la toma de decisiones de mantenimiento para vehículos de nuevas energías mediante la aplicación de árboles de decisión y técnicas de aprendizaje automático. Inicialmente, el estudio analiza cómo se emplean los árboles de decisión y el aprendizaje automático en la elaboración de decisiones de mantenimiento para estos vehículos. Implica la recopilación de datos mediante búsquedas en internet, seguida de análisis estadísticos y preprocesamiento para sentar las bases de futuras investigaciones. Además, la investigación avanza mediante el desarrollo y perfeccionamiento de modelos de árboles de decisión, que facilitan la integración del diagnóstico de fallos y los procesos de toma de decisiones de mantenimiento para vehículos de nuevas energías. Este esfuerzo culmina en el establecimiento de un modelo robusto de árbol de decisión diseñado específicamente para el mantenimiento de vehículos de nuevas energías, que posteriormente se evalúa mediante un estudio de caso detallado. Se presentan los resultados: el grado de aproximación del diagnóstico de fallas en vehículos de nueva energía, basado en el modelo de árbol de decisión, es del 90,58 %, 90,67 %, 88,09 %, 91,28 % y 90,19 %, con un nivel de significancia de α de 0,01, 0,05 y 0,100, respectivamente. Este estudio proporciona una guía teórica sobre la aplicación de árboles de decisión para el diagnóstico y la reparación de fallas en vehículos de nueva energía, con el fin de garantizar el desarrollo de estos vehículos en China.

Angel Peña

En el artículo "**Application of Decision Tree and Machine Learning in New Energy Vehicle Maintenance Decision Making**", Jiang, Li y Cheng (2024) proponen un enfoque basado en árboles de decisión para optimizar el diagnóstico y mantenimiento de vehículos eléctricos. A través del análisis de datos históricos de fallas, sensores internos del automóvil y condiciones externas (como clima y uso), el modelo permite identificar problemas y recomendar acciones específicas de mantenimiento.
Presenta cómo los autores entrenaron un modelo de árbol de decisión con datos recopilados de sensores en tiempo real y registros de mantenimiento, mejorando la eficiencia del diagnóstico automatizado.
Se usaron conjuntos de datos reales recolectados de sistemas a bordo (OBD) en vehículos eléctricos. El algoritmo Decision Tree fue evaluado por su precisión en la predicción de fallas comparado con métodos tradicionales.

Figura 3.



Fuente: Angel Peña (2025).

Conclusión

A través del desarrollo de esta actividad, fue posible comprender de manera integral cómo operan los algoritmos de aprendizaje supervisado, sus diferencias clave y sus ámbitos de aplicación. La elaboración de la infografía permitió visualizar de forma clara sus características y facilitar la comparación entre ellos. Finalmente, la revisión de artículos científicos en Google Scholar evidenció que estas técnicas tienen aplicaciones reales y efectivas en industrias como la automotriz, salud, agricultura y tecnología. Este trabajo fortalece no solo el conocimiento teórico, sino también la habilidad para identificar y evaluar soluciones de inteligencia artificial en contextos reales y actuales.

Bibliografía

Martínez, A. (2021). Árboles de decisión: qué son y cuál es su uso en Big Data. UNIR Revista Ingeniería y Tecnología. Recuperado de https://www.unir.net/revista/ingenieria/arboles-de-decision/

Campo, E. (2016). Introducción a las máquinas de vector soporte (SVM) en aprendizaje supervisado [Tesis de grado, Universidad de Zaragoza]. Zaguan. Recuperado de https://zaguan.unizar.es/record/59156/files/TAZ-TFG-2016-2057.pdf

Datacamp. (2024). Clasificación K vecinos más próximos (KNN) con scikit-learn. Recuperado de https://www.datacamp.com/es/tutorial/k-nearest-neighbor-classification-scikit-learn

Domínguez Martín, M. (2021). Regresión logística y técnicas de aprendizaje. Aplicaciones [Trabajo de Fin de Grado, Universidad de Zaragoza]. Recuperado de https://zaguan.unizar.es/record/110300/files/TAZ-TFG-2021-3094.pdf

Giral, L. et al. (2021). Clasificación de la ocupación espectral para la toma de decisiones en redes inalámbricas cognitivas mediante CNN y SVM. Revista Científica, (…). Recuperado de https://www.scielo.cl/scielo.php?pid=S0718-07642022000400201&script=sci_arttext

Jiang, X., Li, M., & Cheng, L. (2024). Application of Decision Tree and Machine Learning in New Energy Vehicle Maintenance Decision Making. Applied Mathematics and Nonlinear Sciences, 9(1). https://sciendo.com/article/10.2478/amns-2024-1463