UT CHETUMAL

Desarrollo y Gestión de Software

Extracción de conocimiento en bases de datos

Dr. Martín Antonio Santos Romero

T.S.U. Miguel Ángel Peña Pech

9no cuatrimestre

Practica Guiada 2

Importación y exportación de datos

Índice

Introducción 3

Tareas a realizar por el alumno 4

Conclusión 11

Introducción

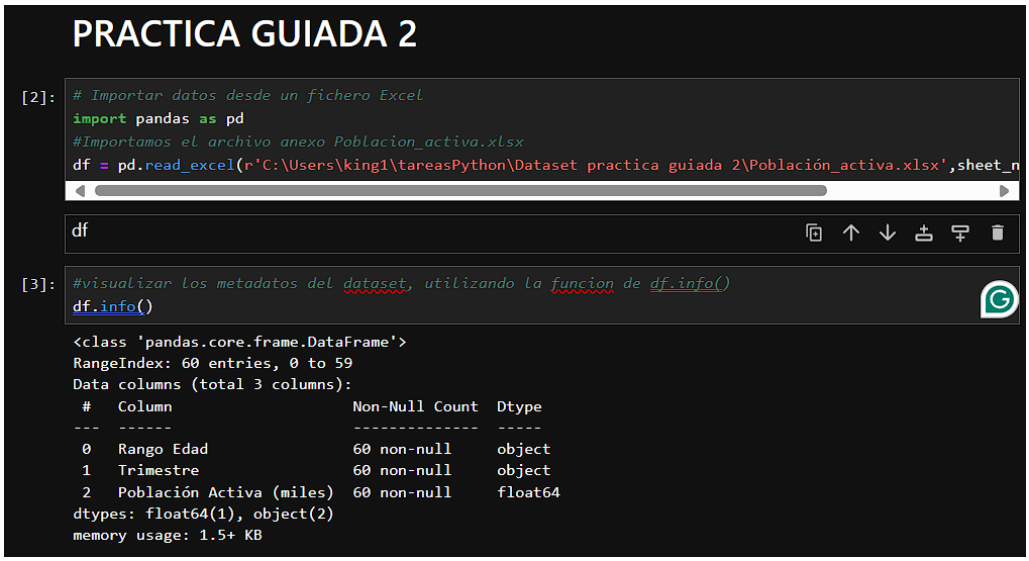
En este ejercicio se trabajó con datos financieros del índice bursátil SP500 (Standard & Poor's 500), utilizando herramientas de análisis de datos en Python. El objetivo principal fue cargar un archivo de Excel con información histórica del índice, calcular la variación porcentual diaria entre el precio de apertura y cierre, y preparar una conexión con una base de datos MySQL para su posterior almacenamiento. Para lograr esto, se emplearon bibliotecas como pandas, sqlalchemy y pymysql, que permiten manipular datos y conectarse con sistemas de gestión de bases de datos de forma eficiente.

Tareas a realizar por el alumno

1. Importar datos desde un archivo Excel

Se importa la biblioteca pandas con el alias pd, luego, se utiliza la función pd.read_excel() para leer un archivo de Excel ubicado en una ruta específica del equipo y visualizamos.
Finalmente, se ejecuta el comando df.info(), el cual muestra información general del DataFrame, como el número de filas y columnas, el tipo de dato en cada columna, la cantidad de valores no nulos, y el uso de memoria.

Figura 1.

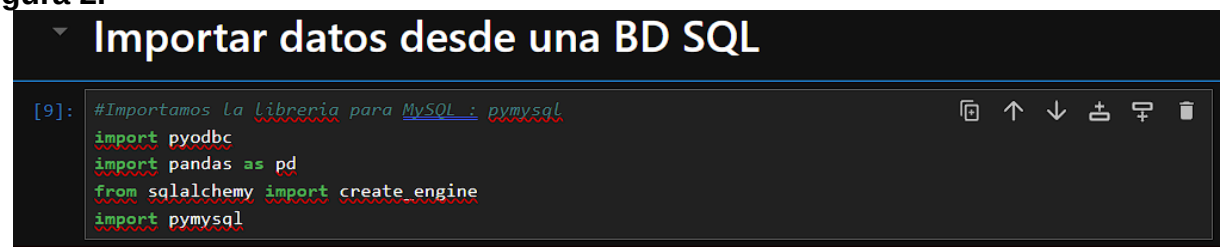


Fuente: Angel Peña (2025).

2. Importar datos desde una BD SQL

Se importan las bibliotecas necesarias para conectarse a bases de datos y manipular datos. Se importa pyodbc, que es un módulo para conectarse a bases de datos mediante el controlador ODBC, pandas con el alias pd para manejar los datos en forma de tablas (DataFrames), y create_engine desde sqlalchemy, que permite construir conexiones con bases de datos de manera sencilla. También se importa pymysql, un módulo que sirve como conector entre Python y bases de datos MySQL.
Se crea una conexión a una base de datos MySQL utilizando create_engine().

Figura 2.



Fuente: Angel Peña (2025).

se conecta al servidor local (127.0.0.1) usando el usuario root y una contraseña ficticia xxxxxx, accediendo a la base de datos llamada cake_cms . Esto crea un motor de conexión llamado db_conexion, que se usará para ejecutar consultas.
Crear un datase utilizado pd.read_sql de pandas, mostramos la información con df.info().

Figura 3.

```
[10]: # Crear conexion a la base de datos, utilizando el metodo  crate_engine
      db_conexion = create_engine('mysql+pymysql://root:@127.0.0.1/cake_cms')

[12]: #crear un datase utilizado pd.read_sql de pandas
      df = pd.read_sql('SELECT * FROM animals', con=db_conexion)
      df
```

[12]:

	id	genero_id	nombre	tipo	habitad	created	modified
0	1	1	Aguila	Volador	Montañas	2025-05-14 00:58:38	2025-05-14 00:58:38
1	2	2	Manatí	Acuatico	Laguna	2025-05-15 01:17:03	2025-05-15 01:17:03

```
[15]: df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2 entries, 0 to 1
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   id          2 non-null      int64
 1   genero_id   2 non-null      int64
 2   nombre      2 non-null      object
 3   tipo        2 non-null      object
 4   habitad     2 non-null      object
 5   created     2 non-null      datetime64[ns]
 6   modified    2 non-null      datetime64[ns]
dtypes: datetime64[ns](2), int64(2), object(3)
memory usage: 244.0+ bytes
```

Fuente: Angel Peña (2025).

3. Importar datos desde archivos ubicados en la web.

Primero, comenzamos importando la librería pandas, que es la herramienta que se va a usar para trabajar con datos en forma de tabla (DataFrame).
Se define la URL desde donde se va a obtener el archivo CSV. En este caso, el archivo se encuentra en el repositorio de aprendizaje automático de la Universidad de California (UCI). La URL contiene un archivo llamado winequality-red.csv, que tiene información sobre la calidad del vino tinto. Lo guardo en una variable llamada url:
El comando para leer el archivo CSV directamente desde la web y cargarlo en un DataFrame (df = pd.read_csv(url, delimiter=";")).

Figura 4.

Importar datos desde archivos ubicados en la web.

```
[13]: #importamos la libreria
      import pandas as pd

[14]: #URL de la base de datos
      url="https://archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-red.csv"

[15]: #Crear un archivo dataset desde un archivo csv en la web
      df = pd.read_csv(url,delimiter=";")
```

```
[20]: df
```

[20]:

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
0	7.4	0.700	0.00	1.9	0.076	11.0	34.0	0.99780	3.51	0.56	9.4	5
1	7.8	0.880	0.00	2.6	0.098	25.0	67.0	0.99680	3.20	0.68	9.8	5
2	7.8	0.760	0.04	2.3	0.092	15.0	54.0	0.99700	3.26	0.65	9.8	5
3	11.2	0.280	0.56	1.9	0.075	17.0	60.0	0.99800	3.16	0.58	9.8	6
4	7.4	0.700	0.00	1.9	0.076	11.0	34.0	0.99780	3.51	0.56	9.4	5
...	...	...	...	...	...	...	...	...	...	...	...	...
1594	6.2	0.600	0.08	2.0	0.090	32.0	44.0	0.99490	3.45	0.58	10.5	5
1595	5.9	0.550	0.10	2.2	0.062	39.0	51.0	0.99512	3.52	0.76	11.2	6
1596	6.3	0.510	0.13	2.3	0.076	29.0	40.0	0.99574	3.42	0.75	11.0	6
1597	5.9	0.645	0.12	2.0	0.075	32.0	44.0	0.99547	3.57	0.71	10.2	5
1598	6.0	0.310	0.47	3.6	0.067	18.0	42.0	0.99549	3.39	0.66	11.0	6

1599 rows × 12 columns

Fuente: Angel Peña (2025).

4. Importar datos desde la web (web scraping).

Importamos las librerías, se usa la URL de la base de datos web y se trae todos los metadatos de la pagina.

Figura 5.



Importar datos desde la web (web scraping).

```
[19]: #Importamos las librerias
      import pandas as pd
      import requests

[20]: #URL de la base de datos web
      url_ej="https://en.wikipedia.org/wiki/List_of_countries_by_average_wage"

[21]: #Trae todos los metadatos de la página web
      r = requests.get(url_ej)
      r.text

[21]: '<!DOCTYPE html>\n<html class="client-nojs vector-feature-language-in-header-enabled vector-feature-lang
      uage-in-main-page-header-disabled vector-feature-page-tools-pinned-disabled vector-feature-toc-pinned-cl
      ientpref-1 vector-feature-main-menu-pinned-disabled vector-feature-limited-width-clientpref-1 vector-fea
      ture-limited-width-content-enabled vector-feature-custom-font-size-clientpref-1 vector-feature-appearanc
      e-pinned-clientpref-1 vector-feature-night-mode-enabled skin-theme-clientpref-day vector-sticky-header-e
      nabled vector-toc-available" lang="en" dir="ltr">\n<head>\n<meta charset="UTF-8">\n<title>List of countr
      ies by average wage - Wikipedia</title>\n<script>(function(){var className="client-js vector-feature-lan
      guage-in-header-enabled vector-feature-language-in-main-page-header-disabled vector-feature-page-tools-p
      inned-disabled vector-feature-toc-pinned-clientpref-1 vector-feature-main-menu-pinned-disabled vector-fe
      ature-limited-width-clientpref-1 vector-feature-limited-width-content-enabled vector-feature-custom-font
      -size-clientpref-1 vector-feature-appearance-pinned-clientpref-1 vector-feature-night-mode-enabled skin-
      theme-clientpref-day vector-sticky-header-enabled vector-toc-available";var cookie=document.cookie.match
      (/(?:^|; )enwikimwclientpreferences=([^;]+)/);if(cookie){cookie[1].split(\'%2C\').forEach(function(pref)
      {className=className.replace(new RegExp(\'(^| )\'+pref.replace(/-clientpref-\\w+$|[^\\w-]+/g,\'\')+\'-cl
      ientpref-\\\\w+( |$)\'),\'$1\'+pref+\'$2\');});};document.documentElement.className=className;}());RLCONF
      ={"wgBreakFrames":false,"wgSeparatorTransformTable":["",""],"wgDigitTransformTable":["",""],"wgDefaultDa
```

Fuente: Angel Peña (2025).

Obtenemos la lista de los elementos de la pagina web y creamos un dataset a partir de los elementos de la pagina web.

Figura 6.

```
[22]: #Obtener lista de los elementos de la pagina web
      df_lista_ej = pd.read_html(r.text)
```

```
C:\Users\king1\AppData\Local\Temp\ipykernel_7040\2542026545.py:2: FutureWarning: Passing literal html to
'read_html' is deprecated and will be removed in a future version. To read from a literal string, wrap i
t in a 'StringIO' object.
  df_lista_ej = pd.read_html(r.text)
```

```
•[24]: #Crear un dataset a partir de los elementos de la página web
       df1 = df_lista_ej[2]
       df1
```

[24]:

	vteEconomic classification of countries	vteEconomic classification of countries.1
0	Developed country Developing country Heavily i...	Developed country Developing country Heavily i...
1	Three/Four-World Model	First World Second World Third World Fourth World
2	Gross domestic product (GDP)	Nominal By country past and projected per capi...
3	Nominal	By country past and projected per capita per c...
4	Purchasing power parity (PPP)	By country future estimates per capita per cap...
5	Gross national income and Income	Disposable income GNI (nominal) per capita GNI...
6	Wages and salary	Average wage Europe Employee compensation (per...
7	Wealth	Wealth inequality Wealth per adult Europe Fina...
8	Other national accounts	Gross National Happiness Net material product ...
9	Human development	Human Development Index by country inequality-...
10	Digital divide	ICT Development Index Number of broadband Inte...

Fuente: Angel Peña (2025).

5. Importar datos desde un archivo JSON

Importamos las librerías necesarias, en este caso la de json y pandas, después abrimos y cargamos los datos desde un archivo JSON y forzamos el tipado o formateado del JSON para después visualizarlo.

Figura 7.

Importar datos desde un archivo JSON

```
[25]: # Importamos librerias
      import json
      import pandas as pd
```

```
[28]: #Abrir y cargar datos desde un archivo JSON
      with open(r'C:\Users\king1\tareasPython\Dataset practica guiada 2\divisions.json', 'r') as json_file:
          json_data = json.load(json_file)
```

```
[29]: #Forzar el tipado o formateado del JSON
      type(json_data)
      json_data
```

```
{'head': {'counts': {'divisionCount': 13915, 'resultCount': 13915}, •••
```

Fuente: Angel Peña (2025).

Creamos un dataset a partir de datos en memoria, usando JSON_normalize pandas y visualizamos.

Figura 8.

```
[30]: #Crear un dataset apartir de datos en memoria, usuando json_normalize pandas
      df = pd.json_normalize(json_data,'results')
      df.head()
```

[30]:

	contextDate	division.outcome	division.debate.uri	division.debate.debateSection	divisio
0	2020-05-27	Carried	https://data.oireachtas.ie/akn/ie/debateRecord...	dbsect_2	
1	2020-05-13	Lost	https://data.oireachtas.ie/akn/ie/debateRecord...	dbsect_2	
2	2020-05-12	Lost	https://data.oireachtas.ie/akn/ie/debateRecord...	dbsect_2	
3	2020-03-26	Lost	https://data.oireachtas.ie/akn/ie/debateRecord...	dbsect_12	

Fuente: Angel Peña (2025).

6. Importar datos desde redes sociales

Importamos a librería de pandas, obtenemos los datos del documento tweets.json, colocando la dirección del documento y visualizamos.

Figura 9.

Importar datos desde redes sociales

```
[45]: #Importar libreria de pandas
      import pandas as pd
```

```
[46]: #Ontencion de los resultados
      df = pd.read_json(r'C:\Users\king1\tareasPython\Dataset practica guiada 2\tweets.json')
      df.head()
```

[46]:

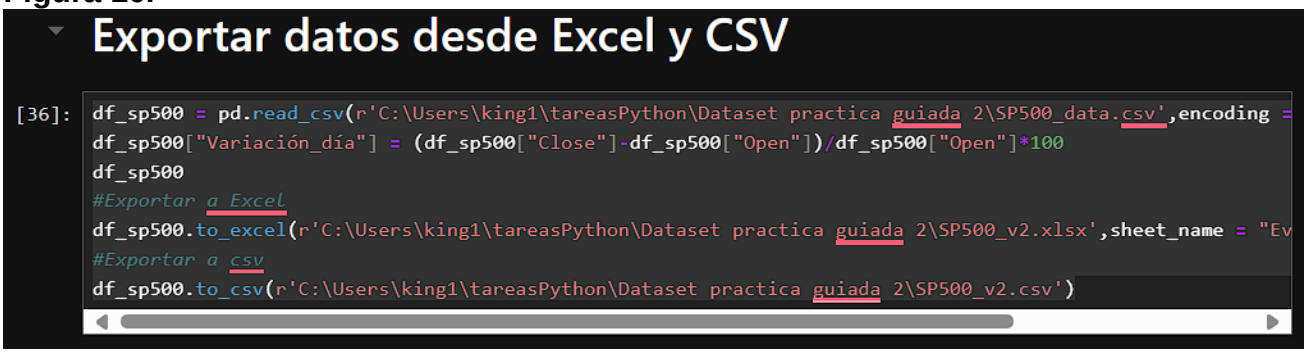
	created_at	id	id_str	text	truncated	entities	
0	2020-06-01 14:24:51+00:00	1267462117617274880	1267462117617274880	RT @nu_alabao: Lo del shock en Madrid es bruta...	False	{'hashtags': [], 'symbols': [], 'user_mentions...	{'iso_lan 'es'
1	2020-06-01 14:24:51+00:00	1267462114786058241	1267462114786058240	RT @nu_alabao: Lo del shock en Madrid es bruta...	False	{'hashtags': [], 'symbols': [], 'user_mentions...	{'iso_lan 'es'
2	2020-06-01 14:24:50+00:00	1267462111560642567	1267462111560642560	@Lucille_84 @mpivila Lo que dice ese señor es ...	True	{'hashtags': [], 'symbols': [], 'user_mentions...	{'iso_lan 'es'

Fuente: Angel Peña (2025).

7. Exportar datos desde Excel y CSV

Primero, se carga el archivo CSV con datos del índice SP500 (Standard & Poor's 500), que se encuentra guardado en una carpeta de la computadora. Para eso, se utiliza la función pd.read_csv() de la librería pandas, y se guarda en una variable llamada df_sp500.
Se especificó la ruta completa del archivo donde esta el CSV y se uso encoding para asegurarse de que se lean correctamente los caracteres especiales y a lo último se indica que los valores del archivo están separados por comas usando delimiter.
Después se calcula la variación porcentual del dia para cada fila de la tabla, usando las columnas Open y Close.
Visualizamos con df_sp500.

Figura 10.

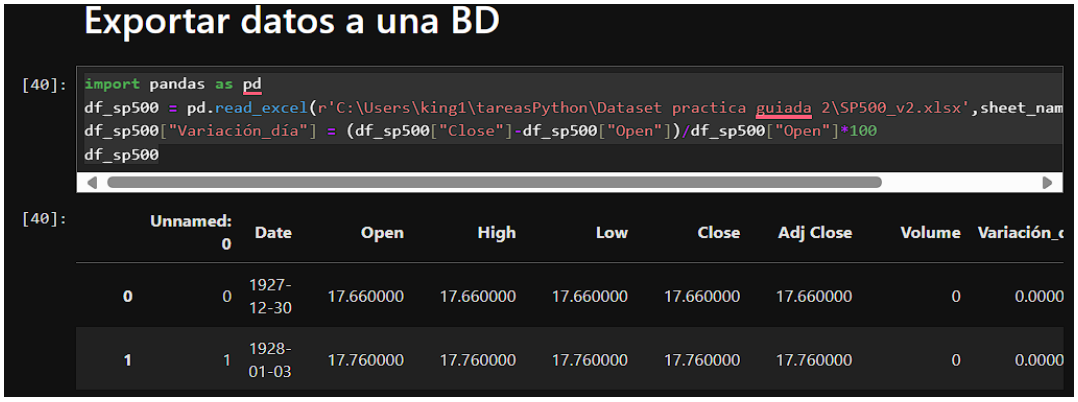


Fuente: Angel Peña (2025).

8. Exportar datos a una BD

Primero, se carga el archivo Excel con datos del índice SP500 (Standard & Poor's 500), el cual se encuentra guardado en una carpeta de la computadora. Para eso, se utiliza la función pd.read_excel() de la librería pandas, y se guarda en una variable llamada df_sp500.
Se especificó la ruta completa del archivo donde está el archivo .xlsx y también el nombre de la hoja (sheet_name="Evolución SP500") que contiene los datos que se desean leer.
Después, se calcula la variación porcentual del día para cada fila de la tabla, usando las columnas "Open" y "Close". La fórmula (Close - Open) / Open * 100 permite saber cuánto subió o bajó el índice SP500 ese día en porcentaje, y el resultado se guarda en una nueva columna llamada "Variación_día".

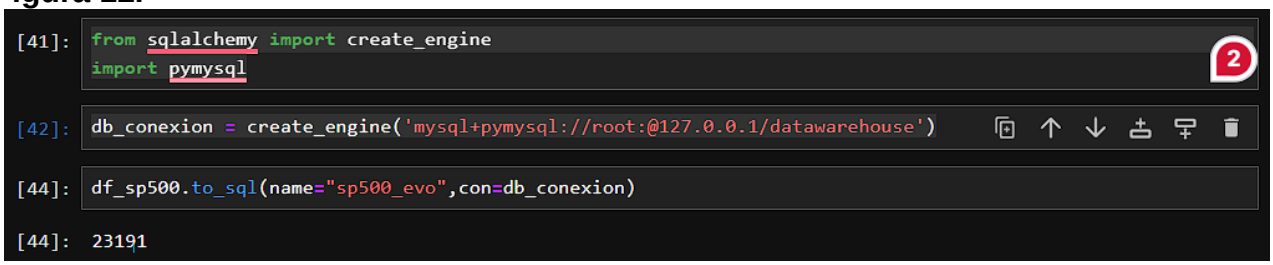
Figura 11.



	Unnamed: 0	Date	Open	High	Low	Close	Adj Close	Volume	Variación_c
0	0	1927-12-30	17.660000	17.660000	17.660000	17.660000	17.660000	0	0.0000
1	1	1928-01-03	17.760000	17.760000	17.760000	17.760000	17.760000	0	0.0000

Fuente: Angel Peña (2025).

Figura 12.



Fuente: Angel Peña (2025).

Conclusión

Al finalizar el ejercicio, se logró leer correctamente los datos desde un archivo Excel, enriquecer el conjunto de datos con una nueva columna que muestra la variación diaria del SP500, y establecer una conexión funcional con una base de datos MySQL. Este proceso es útil en escenarios donde se requiere automatizar el análisis y almacenamiento de datos financieros, y demuestra cómo Python puede integrarse con otras tecnologías para crear flujos de trabajo de análisis de datos más completos y eficientes.